

2020年度特別演習 山下担当分 課題

1AS 岩崎悠紀

2020年6月15日

1 Chapter 1

1.1 Exercise 1.6

■ 課題内容 Consider a following neural network which have 4 neurons in the hidden layer and 3 neurons in the output layer. Calculate outputs where the inputs x , weights w, u and thresholds h, g are given as follows by hand calculation.

■ 解答 手計算で x, w, h, u, g を使って $o(\text{output})$ を出せ, という問題だった. 各変数を以下のよう

に定義する.

$$x = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad w = \begin{bmatrix} 3 & 2 & 2 & 0 \\ 4 & 1 & 5 & 2 \\ 1 & 0 & 1 & 4 \\ 0 & 1 & 0 & 1 \end{bmatrix} \quad h = \begin{bmatrix} 2 \\ 6 \\ 1 \\ 0 \end{bmatrix} \quad u = \begin{bmatrix} 4 & 1 & 4 & 3 \\ 2 & 3 & 0 & 1 \\ 0 & 1 & 2 & 4 \\ 3 & 1 & 1 & 2 \end{bmatrix} \quad g = \begin{bmatrix} 1 \\ 4 \\ 3 \\ 5 \end{bmatrix}$$

まずは一層目の $x \cdot w$ を計算すると,

$$w \cdot x = \begin{bmatrix} 5 & 5 & 3 \\ 9 & 5 & 6 \\ 2 & 1 & 5 \\ 0 & 1 & 1 \end{bmatrix}$$

となり, そこに h より大きい要素を 1, それ以外を 0 にすると以下の行列が求められる.

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

同様に, u, g を用いて $o(\text{output})$ は以下のように導くことができる.

$$u \cdot \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 9 & 7 & 11 \\ 5 & 3 & 3 \\ 3 & 4 & 6 \\ 5 & 5 & 6 \end{bmatrix}$$
$$o = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} \quad (g \text{ をフィルタとして適用})$$

■ **考察** 課題 1.6 ではニューラルネットワークの計算を手でやってみて、実際の処理のイメージを掴むことができた。また、複数のデータを行列にまとめて計算することで効率的に結果を求めることができるということも理解できた。

2 Chapter 2

2.1 Exercise 2.3

■ **課題内容** Based on the XOR function created in exercise 2.2, rewrite the neural network with bias term and step function (i.e., using a class “Affine.m” and “Step.m”) and make sure that the output does not change.

■ **解答** 課題内容は、前課題のソースコードを Affine と Step クラスを使うように修正せよ。また出力が変わっていないか確認する。修正したソースコードとその出力を以下に示す。

ソースコード 1 Exercise 2.3

```
1 import numpy as np
2
3 class Affine:
4     def __init__(self, w, b):
5         self.w = w
6         self.b = b
7
8     def forward(self, x):
9         p = np.dot(self.w, x) + self.b
10        return p
11
12 class Step:
13     def forward(self, x):
14         y = x > 0
15         return y.astype(np.int)
16
17 x = np.array([[0,0,1,1],
18               [0,1,0,1]])
19 w = np.array([[1, 1],
20               [-1, -1]])
21 b = np.array([[0],
22               [2]])
23 u = np.array([1, 1])
24 c = np.array([-1])
25
26 layer1 = Affine(w,b)
27 layer2 = Step()
28 layer3 = Affine(u,c)
29 layer4 = Step()
30
```

```
31 p = layer1.forward(x)
32 y = layer2.forward(p)
33 q = layer3.forward(y)
34 z = layer4.forward(q)
35 print(y)
36 print(z)
```

出力結果

```
[[0 1 1 1]
 [1 1 1 0]]
[0 1 1 0]
```

■ **考察** 本課題ではニューラルネットワークのプログラムを、Affine・Step クラスを使うように修正した。また、修正したプログラムの出力結果を前課題の出力結果と比較した。その結果出力は変えずにプログラムのみを修正することができた。

2.2 Exercise 2.4

■ **課題内容** Implement Sigmoid.m as follows. Then, execute XOR function with sigmoid function and display the output values.

■ **解答** 課題内容はシグモイド関数のクラスを実装し、XOR の出力を表示するというものだった。ソースコードの一部とその出力結果を以下に示す。

ソースコード 2 Exercise 2.4

```
1 class Sigmoid:
2     def forward(self, x):
3         return 1 / (1 + np.exp(-x))
4 x = np.array([[0,0,1,1],
5               [0,1,0,1]])
6 w = np.array([[1, 1],
7               [-1, -1]])
8 b = np.array([[0],
9               [2]])
10 u = np.array([1, 1])
11 c = np.array([-1])
12
13 layer1 = Affine(w,b)
14 layer2 = Sigmoid()
15 layer3 = Affine(u,c)
16 layer4 = Sigmoid()
17
18 p = layer1.forward(x)
19 y = layer2.forward(p)
20 q = layer3.forward(y)
```

```
21 z = layer4.forward(q)
22 print(y)
23 print(z)
```

出力結果

```
[[0.5          0.73105858 0.73105858 0.88079708]
 [0.88079708 0.73105858 0.73105858 0.5          ]]
[0.59406533 0.6135163  0.6135163  0.59406533]
```

■ **考察** 本課題ではシグモイド関数のクラスを実装し、出力を表示した。シグモイド関数はステップ関数のように出力が0と1の2値ではなく、0~1の間で連続した出力が得られる。そのため上記のような出力になったと考えられる。また、後々使用することになると思うが、ステップ関数は離散なため微分できないがシグモイド関数は連続なので微分可能であるため勾配の伝搬ができる。

2.3 Exercise 2.5

■ **課題内容** Displaying output graph with formal neuron. If we use a step function, what kind of graph is outputted?

■ **解答** 課題内容はステップ関数を用いたときの値を可視化するというものだった。ソースコードの一部とその出力結果を以下に示す。

ソースコード 3 Exercise 2.5

```
1 x = np.array([[ 0, 0, 1, 1],
2               [ 0, 1, 0, 1]])
3 w = np.array([[ 2.1, 2.0],
4               [-2.0, -2.0]])
5 b = np.array([[ -1],
6               [ 3]])
7 u = np.array([[ 2, 2]])
8 c = np.array([-3])
9
10 layer1 = Affine(w, b)
11 layer2 = Step()
12 layer3 = Affine(u, c)
13 layer4 = Step()
14
15 p = layer1.forward(x)
16 y = layer2.forward(p)
17 q = layer3.forward(y)
18 z = layer4.forward(q)
19
20 X, Y = np.meshgrid(np.arange(0, 1, 0.01), np.arange(0, 1, 0.01))
21 x = np.vstack((X.reshape(1, 10000), Y.reshape(1, 10000)))
22
```

```

23 p = layer1.forward(x)
24 y = layer2.forward(p)
25 q = layer3.forward(y)
26 z = layer4.forward(q)
27 Z = z.reshape((100, 100))
28
29 fig = plt.figure()
30 ax = fig.gca(projection='3d')
31 ax.plot_surface(X, Y, Z)
32 plt.show()

```




図1 Exercise2.5 の出力結果

■ **考察** 本課題では、ステップ関数を用いたニューラルネットワークの出力をグラフ化して表示した。その事により weight の値によってどうやって出力が変化しているのか視覚化されてわかりやすくなった。

Exercise 2.6

■ **課題内容** If we slightly change the value of weights or biases in exercise2.4.m, please check how the output value changes.

■ **解答** もし weights と biases の値を少し変えたら出力はどうなるのか確認せよという課題だった。ソースコードの一部とその出力結果を以下に示す。

ソースコード 4 Exercise 2.6

```

1 x = np.array([[0,0,1,1],
2               [0,1,0,1]])
3 w = np.array([[1.5, 0.5],
4               [-0.5, -1.1]])
5 b = np.array([[0],
6               [1]])
7 u = np.array([0.5, 1.5])

```

```

8 c = np.array([-2])
9
10 layer1 = Affine(w,b)
11 layer2 = Sigmoid()
12 layer3 = Affine(u,c)
13 layer4 = Sigmoid()
14
15 p = layer1.forward(x)
16 y = layer2.forward(p)
17 q = layer3.forward(y)
18 z = layer4.forward(q)
19 print(y)
20 print(z)

```

出力結果

```

[[0.5          0.62245933 0.81757448 0.88079708]
 [0.73105858 0.47502081 0.62245933 0.35434369]]
[0.34222103 0.27363866 0.34129608 0.26345536]

```

■ **考察** 本課題では、weights や biases を少し変えると出力も少しだけ変わるということが分かった。これにより、ニューラルネットの保持する状態（weight や bias）を少しずつ変化させると出力も少しずつ変えることができるということが分かった。

3 Chapter 3

3.1 Exercise 3.4

■ **課題内容** Check the values of output `y`, `layer1.weights` and `layer1.bias` after learning in `example3_2.m`.

■ **解答** 課題は学習のプログラムを実行した後のレイヤ1の weight と bias を確認せよという課題だった。ソースコードの一部とその出力結果を以下に示す。

ソースコード 5 Exercise 3.4

```

1 class Affine:
2     def __init__(self, w, b):
3         self.w = w
4         self.b = b
5         self.dw = None
6         self.db = None
7         self.input = None
8
9     def forward(self, x):
10        self.input = x
11        y = np.dot(self.w, x) + self.b

```

```

12         return y
13
14     def backward(self, dx):
15         self.dw = np.dot(dx, self.input.T)
16         self.db = np.sum(dx, axis=1, keepdims=True)
17         return np.dot(self.w.T, dx)
18
19     def update(self, lr=0.1):
20         self.w -= self.dw * lr
21         self.b -= self.db * lr
22
23 class Sigmoid:
24     def __init__(self):
25         self.output = None
26
27     def forward(self, x):
28         y = 1 / (1 + np.exp(-x))
29         self.output = y
30         return y
31
32     def backward(self, dx):
33         return dx * self.output * (1.0 - self.output)
34
35
36 x = np.array([[0, 0, 1, 1],
37               [0, 1, 0, 1]])
38 t = np.array([0, 0, 0, 1])
39
40 input_dim = 2
41 hidden_dim = 2
42 output_dim = 1
43
44 w = 2.0 * np.random.rand(1, 2) - 1.0
45 b = 2.0 * np.random.rand(1, 1) - 1.0
46
47 layer1 = Affine(w, b)
48 layer2 = Sigmoid()
49 layer3 = MSE()
50
51 epoch = 1000
52 for i in range(epoch):
53     p = layer1.forward(x)
54     y = layer2.forward(p)
55     loss = layer3.forward(y, t)
56
57     dy = layer3.backward()
58     dp = layer2.backward(dy)

```

```

59     dx = layer1.backward(dp)
60
61     layer1.update()
62
63     if i % 100 == 0:
64         print('epoch', i, 'loss', loss, 'y', y)
65
66     print(layer1.w)
67     print(layer1.b)

```

出力結果

```

epoch 0 loss 0.11059875819525353 y [[0.30140249 0.16058501 0.36526844 0.20329552]]
epoch 100 loss 0.07264510880272602 y [[0.22688731 0.27025334 0.39495912 0.45168125]]
epoch 200 loss 0.0527648595295762 y [[0.14751532 0.29044564 0.34971152 0.55988491]]
epoch 300 loss 0.0417154667463111 y [[0.09939268 0.28169867 0.30972685 0.61456522]]
epoch 400 loss 0.03449939597385088 y [[0.07045038 0.26694585 0.28070435 0.65218267]]
epoch 500 loss 0.029323894473012743 y [[0.05202754 0.25143319 0.25849141 0.68086392]]
epoch 600 loss 0.025403024800220022 y [[0.03971709 0.23684354 0.24062763 0.70394218]]
epoch 700 loss 0.022326384745484495 y [[0.03115796 0.22363927 0.22575441 0.72312334]]
epoch 800 loss 0.019851247873327545 y [[0.02500759 0.21184582 0.21307449 0.73941371]]
epoch 900 loss 0.017821589787150982 y [[0.02046322 0.20134291 0.20208214 0.75346842]]
[[2.62166652 2.61870924]]
[[-4.05594338]]

```

■ **考察** 本課題では AND 回路の入力と出力を使ってニューラルネットワークを学習させた。そして実行したあとのレイヤ 1 のウェイトとバイアスとそれらを使った出力を表示させた。しかし、結果を見たところ学習しきっているようには見えなかった。ただ、損失関数の値の下がり具合を見ると、学習途中のように見えたのでエポックを増やせばまだ損失は下がりそうだと感じた。

3.2 Exercise 3.5

■ **課題内容** Check the values of weights and biases after learning in example3_3.m and write down these values to one places of decimals. Then, calculate XOR output by your hand calculation with step function.

■ **解答** 課題内容は XOR の入力と出力を使ってニューラルネットワークを学習させ、各レイヤのウェイトとバイアスを表示させ手作業で計算もするということがあった。ソースコードと出力結果、手作業で計算した結果を以下に示す。

ソースコード 6 Exercise 3.5

```

1 x = np.array([[0, 0, 1, 1],
2               [0, 1, 0, 1]])
3 t = np.array([0, 1, 1, 0])
4
5 input_dim = 2
6 hidden_dim = 2
7 output_dim = 1

```



```

8
9 w = 2.0 * np.random.rand(hidden_dim, input_dim) - 1.0
10 b = 2.0 * np.random.rand(hidden_dim, 1) - 1.0
11 u = 2.0 * np.random.rand(output_dim, hidden_dim) - 1.0
12 c = 2.0 * np.random.rand(output_dim, 1) - 1.0
13
14 layer1 = Affine(w, b)
15 layer2 = Sigmoid()
16 layer3 = Affine(u, c)
17 layer4 = Sigmoid()
18 layer5 = MSE()
19
20 epoch = 1000
21 for i in range(epoch):
22     p = layer1.forward(x)
23     y = layer2.forward(p)
24     q = layer3.forward(y)
25     z = layer4.forward(q)
26     loss = layer5.forward(z, t)
27
28     dz = layer5.backward()
29     dq = layer4.backward(dz)
30     dy = layer3.backward(dq)
31     dp = layer2.backward(dy)
32     dx = layer1.backward(dp)
33
34     layer1.update(1.0)
35     layer3.update(1.0)
36
37     if i % 100 == 0:
38         print('epoch', i, 'loss', loss, 'z', z)

```

出力結果

```
epoch 0 loss 0.14865152481975835 z [[0.30973394 0.29240501 0.27691086 0.26406156]]
epoch 100 loss 0.12493005821637666 z [[0.51293776 0.50855688 0.49162716 0.4861852 ]]
epoch 200 loss 0.12465843369022318 z [[0.51062719 0.51422939 0.48651222 0.48670789]]
epoch 300 loss 0.12365131549983245 z [[0.51059522 0.53086825 0.47145759 0.47860356]]
epoch 400 loss 0.11606619291149047 z [[0.49631644 0.6006541 0.42374649 0.43663975]]
epoch 500 loss 0.0929762025847744 z [[0.45748439 0.74956163 0.39729043 0.32945326]]
epoch 600 loss 0.04646288191252964 z [[0.35850376 0.79248915 0.60704202 0.21377882]]
epoch 700 loss 0.009311833893073414 z [[0.14334216 0.86844748 0.8509094 0.12005676]]
epoch 800 loss 0.004461025559716306 z [[0.09645524 0.90192461 0.90219031 0.08484735]]
epoch 900 loss 0.0028436916336632635 z [[0.07621343 0.91943909 0.92374011 0.06808389]]
[[ 4.22786955 -4.5941637 ]
 [ 5.50647153 -5.78792623]]
[[-2.25110444]
 [ 3.17054042]]
[[ 7.18034835 -6.66447265]]
[[3.03835718]]
```

1000 エポック分学習させた状態で出力を手計算でステップ関数を適用させると、

$$\begin{bmatrix} 0.1 & 0.9 & 0.9 & 0.1 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 1 & 0 \end{bmatrix} \quad (\text{ステップ関数適用})$$

■ **考察** 本課題で XOR の入力と出力を学習させて、その出力を手計算でステップ関数を適用させた。まず、前提として資料に載っていた学習設定では学習しきっていなさそうだったため、学習率を 0.1 から 1.0 まで引き上げた。そうしたら 500 エポックを超え始めたあたりから急激に損失関数の出力が下がりはじめた様に見えた。また、実際に手作業でステップ関数も適用させた結果から正しく学習できているということが分かった。

4 Chapter 4

4.1 Exercise 4.3

■ **課題内容** Try to increase the performance of the neural network by setting the parameter to various values. Consider the recognition accuracy, parameter values such as the number of hidden layer neurons, learning rate, epoch number and initial weights and biases, and what kind of images are difficult to recognize, and put the consideration and findings together in your final report.

■ **解答** 課題内容が Exercise4.2 で学習させた結果より精度を上げるためにハイパーパラメータなどを変更せよとのことだった。まずは Exercise4.2 の出力を以下に示す。

出力結果

```
epoch:0 loss:0.3379676518566211
epoch:1 loss:0.23594588128504435
epoch:2 loss:0.1722073375253008
epoch:3 loss:0.13766380775297515
epoch:4 loss:0.1176365801136934

[[5523  2  83  18  19 120  73  29  53  3]
 [  4 6489  45  37  12  27  12  18  83 15]
 [ 107  85 4932 140 144  24 196 116 183 31]
 [ 101  79 157 5163  15 307  33  71 139 66]
 [  6  45  69  7 5250  11 121  17  25 291]
 [ 208  61  54 305  75 4121 151  49 319 78]
 [  84  40  86  6  49 151 5418  8  72  4]
 [  29  90  74  80 123  21  10 5516  28 294]
 [  21 166 124 243  83 376  59  34 4620 125]
 [  28  39  36  69 281  53  8 214  93 5128]]
train_accuary=0.8693333333333333

[[ 940  0  2  3  1 13  9  5  6  1]
 [  0 1102  5  4  1  2  5  1 14  1]
 [ 17  12 859  20 22  2 27 24 38 11]
 [ 13  14  32 848  4 49  2 11 27 10]
 [  2  3  4  1 885  1 29  0  2 55]
 [ 26  8  5  58 12 681 18 16 54 14]
 [ 17  7  6  2  9 29 874  5  6  3]
 [ 10 21 26 11 15  1  1 888  0 55]
 [  5 19 14 30 17 58 10 11 783 27]
 [  2  6  3  9 38 13  4 17 10 907]]
test_accuary=0.8767
```




図2 MNIST データにおける FFN モデル学習時の損失関数

以上の結果から精度を上げるためにハイパーパラメータを変更した。具体的にはエポックを5から20, 中間層の次元数を10から50に変更すると以下のような結果が得られた。また, そのソースコードも以下に示す。

```

1 class Dataset:
2     def __init__(self, data_dir=None, data=None, transform=None, train=True):
3         self.data_dir = data_dir
4         self.transform = transform
5         self.train = train
6
7     def __getitem__(self, idx):
8         raise NotImplementedError
9
10
11 class MNISTDataset(Dataset):
12
13     urls = [
14         'http://yann.lecun.com/exdb/mnist/train-images-idx3-ubyte.gz',
15         'http://yann.lecun.com/exdb/mnist/train-labels-idx1-ubyte.gz',
16         'http://yann.lecun.com/exdb/mnist/t10k-images-idx3-ubyte.gz',
17         'http://yann.lecun.com/exdb/mnist/t10k-labels-idx1-ubyte.gz',
18     ]
19
20     def __init__(self, data_dir, transform=None, train=True):
21         super(MNISTDataset, self).__init__(data_dir,
22                                             transform=transform,
23                                             train=train)
24
25         if not self._exist_data():
26             print('Start downloading MNIST data from http://yann.lecun.com/exdb/mnist')
27             self.download()
28             print('Complete!')
29
30         if self.train:
31             self.data = (
32                 read_mnist_data(os.path.join(self.data_dir, 'train-images-idx3-ubyte.gz')),
33                 read_mnist_data(os.path.join(self.data_dir, 'train-labels-idx1-ubyte.gz')),
34             )
35         else:
36             self.data = (
37                 read_mnist_data(os.path.join(self.data_dir, 't10k-images-idx3-ubyte.gz')),
38                 read_mnist_data(os.path.join(self.data_dir, 't10k-labels-idx1-ubyte.gz')),
39             )
40
41     def __getitem__(self, idx):
42         images = self.data[0][idx]
43         labels = self.data[1][idx]
44
45         if self.transform:
46             images, labels = self.transform((images, labels))
47
48         return images, labels
49
50     def __len__(self):
51         return self.data[0].shape[0]
52
53     def download(self):
54         import urllib.request
55
56         os.makedirs(self.data_dir, exist_ok=True)

```

```

57
58     for url in self.urls:
59         filename = url.rpartition('/')[2]
60         urllib.request.urlretrieve(url, os.path.join(self.data_dir, filename))
61
62     return
63
64     def _exist_data(self):
65         for url in self.urls:
66             filename = url.rpartition('/')[2]
67             if not os.path.isfile(os.path.join(self.data_dir, filename)):
68                 return False
69
70     return True
71
72
73 class DataLoader:
74     def __init__(self, dataset, batch_size=100):
75         self.dataset = dataset
76         self._batch_size = batch_size
77         self._i = 0
78
79     def __iter__(self):
80         return self
81
82     def __next__(self):
83         if (self._i * self._batch_size) >= len(self.dataset):
84             self._i = 0
85             raise StopIteration
86         elif ((self._i + 1) * self._batch_size) >= len(self.dataset):
87             x, y = self.dataset[self._i * self._batch_size:]
88         else:
89             x, y = self.dataset[self._i * self._batch_size:(self._i + 1) * self._batch_size]
90
91         self._i += 1
92         return x, y
93
94
95 def read_mnist_data(filepath):
96     import gzip, codecs
97     with gzip.open(filepath, 'rb') as f:
98         data = f.read()
99
100     magic = int(codecs.encode(data[0:4], 'hex'), 16)
101     nd = magic % 256
102     ty = magic // 256
103     data_num = int(codecs.encode(data[4:8], 'hex'), 16)
104
105     return np.frombuffer(data, dtype=np.uint8, offset=(4 * (nd + 1))).reshape(data_num,
106                                         -1)
107
108 class MNISTTransform:
109     def __init__(self):
110         pass
111
112     def __call__(self, data):
113         x = data[0] / 255
114         y = np.identity(10)[data[1].flatten()]

```

```

115
116         return (x, y)
117
118 epochs = 20 # 5 -> 変更 20
119 batch_size = 100
120 input_dim = 784
121 hidden_dim = 50 # 10 -> 変更 50
122 output_dim = 10
123
124 mnist_train = MNISTDataset('../data/mnist', transform=MNISTTransform(), train=True)
125 mnist_test = MNISTDataset('../data/mnist', transform=MNISTTransform(), train=False)
126 dataloader_train = DataLoader(mnist_train, batch_size=batch_size)
127 dataloader_test = DataLoader(mnist_test, batch_size=batch_size)
128
129 w = np.random.randn(hidden_dim, input_dim)
130 b = np.random.randn(hidden_dim, 1)
131 u = np.random.randn(output_dim, hidden_dim)
132 c = np.random.randn(output_dim, 1)
133
134 layer1 = Affine(w, b)
135 layer2 = Sigmoid()
136 layer3 = Affine(u, c)
137 layer4 = Sigmoid()
138 layer5 = MSE()
139
140 loss = []
141
142 for epoch in range(epochs):
143     predicts = []
144     for x, y in dataloader_train:
145         p = layer1.forward(x.T)
146         t = layer2.forward(p)
147         q = layer3.forward(t)
148         z = layer4.forward(q)
149         predicts.append(list(z.T))
150         loss.append(layer5.forward(z, y.T))
151
152         dz = layer5.backward()
153         dq = layer4.backward(dz)
154         dt = layer3.backward(dq)
155         dp = layer2.backward(dt)
156         dx = layer1.backward(dp)
157
158         layer1.update(lr=0.05)
159         layer3.update(lr=0.05)
160     print('epoch:{epoch} loss:{loss}'.format(epoch=epoch, loss=loss[-1]))
161
162 images, labels = mnist_train[0:]
163 predicts = np.identity(10)[np.argmax(np.array(predicts).reshape(-1, 10), axis=1)]
164 results = np.dot(labels.T, predicts).astype(np.int32)
165
166 print(results)
167 print('accuary={}'.format(np.diag(results).sum() / results.sum()))
168
169 plt.plot(np.arange(12000), np.array(loss))
170 plt.title('Training loss of FFN with MNIST')
171 plt.xlabel('batch')
172 plt.ylabel('loss')
173 plt.show()

```

```

174
175 predicts = []
176
177 for x, y in dataloader_test:
178     p = layer1.forward(x.T)
179     y = layer2.forward(p)
180     q = layer3.forward(y)
181     z = layer4.forward(q)
182     predicts.append(list(z.T))
183
184 images, labels = mnist_test[0:]
185 predicts = np.identity(10)[np.argmax(np.array(predicts).reshape(-1, 10), axis=1)]
186 results = np.dot(labels.T, predicts).astype(np.int32)
187
188 print(results)
189 print('accuary={}'.format(np.diag(results).sum() / results.sum()))

```

出力結果

```
epoch:0 loss:0.2523595456655897
epoch:1 loss:0.1783767324616495
epoch:2 loss:0.13051501818352595
epoch:3 loss:0.11571855536826176
epoch:4 loss:0.08457559114881316
epoch:5 loss:0.05905629578978815
epoch:6 loss:0.051956685309520426
epoch:7 loss:0.047524731738717844
epoch:8 loss:0.04473252626393911
epoch:9 loss:0.04225189062581892
epoch:10 loss:0.03969878490015143
epoch:11 loss:0.037133564395709875
epoch:12 loss:0.03470599079638301
epoch:13 loss:0.03251194227002699
epoch:14 loss:0.030504217377877056
epoch:15 loss:0.028733949273416725
epoch:16 loss:0.02733138361801906
epoch:17 loss:0.026216503928003555
epoch:18 loss:0.025227079373516093
epoch:19 loss:0.024355322842522995
```

```
[[5799    1    9    3    9   17   29    9   42    5]
 [   3 6616   30   23    7    7    7   15   24   10]
 [   27   18 5635   44   51   10   40   49   71   13]
 [   16   16   99 5700    7   92   15   61   89   36]
 [   11   20   20    2 5591    4   28   16   12  138]
 [   32   12   27   79   26 5093   42   21   50   39]
 [   36    6   10    0   29   48 5759    2   25    3]
 [   11   26   47   15   41    3    3 6034   16   69]
 [   24   44   38   74   16   52   25   17 5519   42]
 [   33    9    9   59  102   21   10   82   52 5572]]
```

accuary=0.9553

```
[[ 959    0    0    2    2    4    6    3    4    0]
 [   0 1118    3    2    1    2    3    1    5    0]
 [   5    2  951   14   13    4    8   15   18    2]
 [   0    1   10  942    1   16    0   10   22    8]
 [   2    1    3    1  928    0    7    1    3   36]
 [   6    1    0   21    4  823    9    2   18    8]
 [  12    3    5    0    7   12  911    1    7    0]
 [   1    8   20    5    6    1    0  964    2   21]
 [   5    3    3   13   10   17    8    9  894   12]
 [   6    6    1    6   24   14    3    8    5  936]]
```

accuary=0.9426

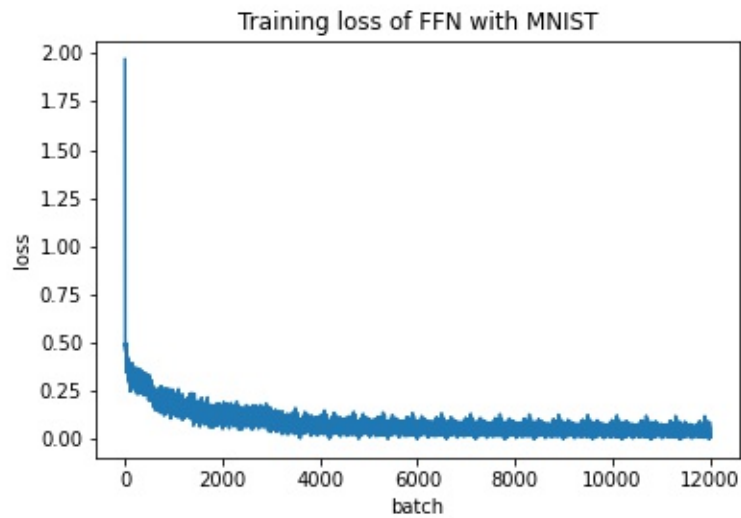


図3 ハイパーパラメータを変更した後のモデル学習時の損失関数

■ **考察** まず、前課題で学習させたモデルの train, test の各精度は 86.93% と 87.67% となっていた。そこからハイパーパラメータのエポック数と中間層の次元数をそれぞれ 5 から 20, 10 から 50 というふうに変えて再度モデルを学習させた。そうしたら train, test の各精度は 95.53%, 94.26% と約 10% 近くも向上した。エポック数を増やすと学習がより進み、中間層の次元を増やすとより柔軟なモデルにすることができ、モデルの表現力が上がる。その双方の効果が出て 10% 近くも精度が向上したのではないかと考えた。